

Fundamentos de Big Data (part 2) Centro Universitário 7 Setembro - Uni7

Especialização em Ciência de Dados com Big Data, BI e Data Analytics

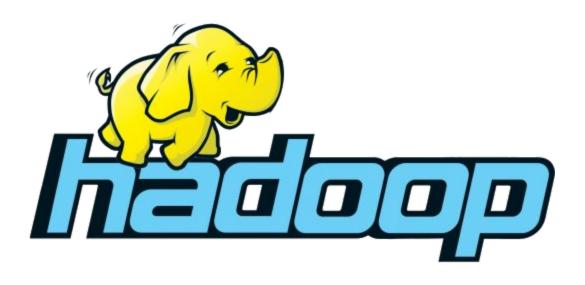
Prof. Manoel Ribeiro

# Conteúdo da disciplina (20 h/a)

- Dia 2 (8h/a)
  - Introdução ao OpenStack
  - o Introdução à Arquitetura e ao Ecossistema **Hadoop**.
  - Introdução ao Apache Spark.
  - Introdução aos Bancos de Dados NoSQL
  - Introdução ao MongoDB







# Hadoop - setup for single node

>PATH=%hadoop\_home%\bin

edit %hadoop\_home%/etc/hadoop/core-site.xml

### edit %hadoop\_home%/etc/hadoop/hdfs-site.xml:

https://hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-common/SingleCluster.html

## Hadoop - Start

- >cd %hadoop\_home%\bin
- >hadoop namenode -format
- \*\* check pasta /tmp/hadoop-<user>
- >cd %hadoop\_home%\sbin
- >start\_yarn.cmd
  - Resource manager
  - Node Manager

# Hadoop - Start

>start\_dfs.cmd

- Hadoop namenode
- Hadoop datanode

### **HADOOP LIVE!**

http://localhost:8088

### RM Home



### **All Applications**



### Cluster Metrics

Showing 0 to 0 of 0 entries

Apps			Apps			Apps	Containers		Memory	100000000000000000000000000000000000000		
Submitted		ed	Pending	Runi	ning Completed		Running		Used	Total		
0 0		Ü.	0	0		0		0 B	8 GB			
Clus	ter No	des Me	etrics									
Active Nodes			Deco	Decommissioning Nodes De			ecommissioned Nodes Los			t Nodes Unhe		
1	<u>1</u> <u>0</u>		0	<u>0</u>				<u>0</u>		0	0	
Sche	eduler	Metrics	5									
Scheduler Type				Scheduling Resource Type			Minimum Allocation			Maximum		
Capacity Scheduler				MEMORY]			<memory:1024, vcores:1=""></memory:1024,>			<memory:8192, td="" v<=""></memory:8192,>		
Sho	w 20	∨ entrie	·S									
ID	User	Name	Application Type \$	Queue	Application Priority \$	StartTime	FinishTime	State	FinalStatus	Running Containers	Alloca CP VCo	
								No d	ata available i	n table		

## Hadoop - Shutdown

>cd %hadoop\_home%\sbin

>stop\_yarn.cmd

>stop\_dfs.cmd



## Spark - Dataset para Demo

Portal da transparência - Brasil - Gastos

<a href="http://www.portaldatransparencia.gov.br/downloads/mensal.asp?c=GastosDiretos#meses02">http://www.portaldatransparencia.gov.br/downloads/mensal.asp?c=GastosDiretos#meses02</a>

Despesas - Gastos Diretos - Pagamentos - fev/2017 - 392 MB

```
>iconv -f ISO-8859-1 -t UTF-8 201702 GastosDiretos.csv >
201702_GastosDiretos-utf8.csv
>pyspark
>>> df=spark.read.format("com.databricks.spark.csv").option("header",
"true").option("delimiter", "\t").option("inferSchema",
"True").load('/bigdata/dataset/201702_GastosDiretos-utf.csv')
>>>df.count()
```

```
>>> df.printSchema()
root
 -- Código Órgão Superior: integer (nullable = true)
 -- Nome Órgão Superior: string (nullable = true)
 -- Código Órgão: integer (nullable = true)
 -- Nome Órgao: string (nullable = true)
 -- Código Unidade Gestora: integer (nullable = true)
 -- Nome Unidade Gestora: string (nullable = true)
 -- Código Grupo Despesa: integer (nullable = true)
 -- Nome Grupo Despesa: string (nullable = true)
 -- Código Elemento Despesa: integer (nullable = true)
 -- Nome Elemento Despesa: string (nullable = true)
 -- Código Função: integer (nullable = true)
 -- Nome Função: string (nullable = true)
 -- Código Subfunção: integer (nullable = true)
 -- Nome Subfunção: string (nullable = true)
 -- Código Programa: integer (nullable = true)
 -- Nome Programa: string (nullable = true)
 -- Código Ação: string (nullable = true)
 -- Nome Ação: string (nullable = true)
 -- Linguagem Cidadã: string (nullable = true)
```

- -- Código Favorecido: string (nullable = true)
- -- Nome Favorecido: string (nullable = true)
- -- Número Documento: string (nullable = true)
- -- Gestão Pagamento: string (nullable = true)
- -- Data Pagamento: string (nullable = true)
- -- Valor: double (nullable = true)

>>>df.select("Nome Órgão Superior").show(10, truncate=False)

```
|Nome Órgão Superior |
| PRESIDENCIA DA REPUBLICA |
| PRESIDENCIA DA REPUBLICA |
|PRESIDENCIA DA REPUBLICA|
| PRESIDENCIA DA REPUBLICA |
|PRESIDENCIA DA REPUBLICA|
|PRESIDENCIA DA REPUBLICA|
| PRESIDENCIA DA REPUBLICA |
+----+
only showing top 10 rows
```

>>>df.select("Nome Órgão Superior").distinct().show(10,truncate=False)

```
|Nome Órgão Superior
IMINISTERIO DA PREVIDENCIA SOCIAL
|MINISTERIO DA SAUDE
PRESIDENCIA DA REPUBLICA
IMINISTERIO DA DEFESA
IMINIST. DA AGRICUI...PECUARIA E ABASTECIMENTO
MINIST. DO PLANEJAMENTO. DESENVOLV. E GESTAO
|MINISTERIO DAS RELACOES EXTERIORES
IMINISTERIO DO METO AMBIENTE
|MINISTERIO DO DESENVOLVIMENTO SOCIAL
|MINIST.DA CIENCIA.TECNOL..INOV.E COMUNICACOES|
only showing top 10 rows
```

>>>df.select("Nome Órgão Superior").distinct().show(10,truncate=False)

```
|Nome Órgão Superior
IMINISTERIO DA PREVIDENCIA SOCIAL
|MINISTERIO DA SAUDE
PRESIDENCIA DA REPUBLICA
IMINISTERIO DA DEFESA
IMINIST. DA AGRICUI...PECUARIA E ABASTECIMENTO
MINIST. DO PLANEJAMENTO. DESENVOLV. E GESTAO
|MINISTERIO DAS RELACOES EXTERIORES
IMINISTERIO DO METO AMBIENTE
|MINISTERIO DO DESENVOLVIMENTO SOCIAL
|MINIST.DA CIENCIA.TECNOL..INOV.E COMUNICACOES|
only showing top 10 rows
```

>>>df.filter(df["Nome Órgão Superior"]=="MINISTERIO DO TRABALHO").count()

4410

>>> df.groupBy("Nome Órgão Superior").count().orderBy("count").show(5, False)

### >>> df.groupBy("Nome Órgão Superior").sum("Valor").show(10, False)

```
-----
                          |sum(Valor) |
|Nome Órgão Superior
  -----+
MINISTERIO DA PREVIDENCIA SOCIAL |1.9915093517999896E8|
                   |1.8933997643299787E9|
|1.1735994061000007E8|
|MINISTERIO DA SAUDE
PRESTDENCIA DA REPUBLICA
                  |6.417606468800002E8 |
|MINISTERIO DA DEFESA
MINIST. DA AGRICUL..PECUARIA E ABASTECIMENTO |1.2012305850999987E8|
|MINIST. DO PLANEJAMENTO. DESENVOLV. E GESTAO |4.9010021770000115E7|
MINISTERIO DAS RELACOES EXTERIORES |1.0862974240000006E7|
                     |4.239037645999985E7 |
MINISTERIO DO MEIO AMBIENTE
MINISTERIO DO DESENVOLVIMENTO SOCIAL | 1.9672350602999988E8 |
|MINIST.DA CIENCIA.TECNOL..INOV.E COMUNICACOES|4.0943230055000174E8|
   -----+
only showing top 10 rows
```

Responda: Qual o órgão Superior que mais gastou em fevereiro/2017?

```
>>> to_float = lambda x: float(x.replace(",","."))
>>> from pyspark.sql import functions as SQL
>>> from pyspark.sql.types import FloatType
>>> udf_to_float = SQL.udf(to_float, FloatType())
>>> df2=df.withColumn("ValorFloat",udf_to_float(df["Valor"]))
```

### >>>df2.printSchema()

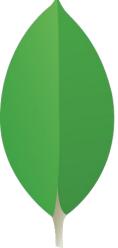
### root

- -- Código Órgão Superior: string (nullable = true)
- -- Nome Órgão Superior: string (nullable = true)
- -- Código Órgão: string (nullable = true)
- -- Nome Órgao: string (nullable = true)
- -- Código Unidade Gestora: string (nullable = true)
- -- Nome Unidade Gestora: string (nullable = true)
- -- Código Grupo Despesa: string (nullable = true)
- |-- Nome Grupo Despesa: string (nullable = true)

### \*\*\*

- -- Nome Favorecido: string (nullable = true)
- -- Número Documento: string (nullable = true)
- -- Gestão Pagamento: string (nullable = true)
- -- Data Pagamento: string (nullable = true)
- -- Valor: string (nullable = true)
- |-- ValorFloat: float (nullable = true)

# Not SQL



# mongoDB®

MongoDB Community Server

https://www.mongodb.com/community

https://www.mongodb.com/download-center?jmp=nav#community

Install custom to c:\bigdata\mongodb

- >cd \bigdata\mongodb\
- >mkdir data
- >cd data
- >mkdir db
- >cd \bigdata\mongodb\
- >mkdir log
- >mongod -directoryperdb -dbpath=c:\bigdata\mongodb\data\db
- -logpath=c:\bigdata\mongodb\log\mongo.log -logappend -rest -install

### >net start MongoDB

O serviço de MongoDB está sendo iniciado..

O serviço de MongoDB foi iniciado com êxito.

\*\* Verificar mongo.log

\*\*\* [initandlisten] Service running

\*\*\*[thread1] waiting for connections on port 27017

### >cd \bigdata\mongodb\

### >mongo

>

```
connecting to: mongodb://127.0.0.1:27017
MongoDB server version: 3.4.9
Server has startup warnings:
2017-10-19T09:44:25.519-0300 | CONTROL [initandlisten]
2017-10-19T09:44:25.519-0300 | CONTROL [initandlisten] ** WARNING: Access control is not enabled for the database.
2017-10-19T09:44:25.523-0300 | CONTROL [initandlisten] ** Read and write access to data and configuration is unrestricted.
2017-10-19T09:44:25.524-0300 | CONTROL [initandlisten]
```

### >help

```
db.help()
                             help on db methods
                             help on collection methods
db.mycoll.help()
sh.help()
                             sharding helpers
rs.help()
                             replica set helpers
help admin
                             administrative help
help connect
                             connecting to a db help
help keys
                             kev shortcuts
                             misc things to know
help misc
help mr
                             mapreduce
show dbs
                             show database names
show collections
                             show collections in current database
show users
                             show users in current database
show profile
                             show most recent system.profile entries with time >= 1ms
show logs
                             show the accessible logger names
                             prints out the last segment of log in memory, 'global' is default
show log [name]
use <db name>
                             set current database
db.foo.find()
                             list objects in collection foo
db.foo.find( { a : 1 } )
                            list objects in foo where a == 1
                             result of the last line evaluated; use to further iterate
it.
                            set default number of items to display on shell
DBQuery.shellBatchSize = x
exit
                             quit the mongo shell
```

```
> show dbs
admin 0.000GB
local 0.000GB
```

- > use bigdataswitched to db bigdata
- > **db** bigdata
- > db.ListaTelefonica.insert({Nome:"Paulo", Telefone:"(85) 929292"})

WriteResult({ "nInserted": 1 })

> db.ListaTelefonica.insert({Nome:"Policia", Telefone:"190"})

WriteResult({ "nInserted" : 1 })

```
> show dbs
admin 0.000GB
bigdata 0.000GB
local 0.000GB
> show collections
ListaTelefonica
> db.ListaTelefonica.find()
{ "_id" : ObjectId("59e8b136dfa9a3fbf0fd8238"), "Nome" : "Paulo", "Telefone" :
"(85) 929292" }
{ " id" : ObjectId("59e8b146dfa9a3fbf0fd8239"), "Nome" : "Policia", "Telefone" :
"190" }
```

```
> db.ListaTelefonica.find().pretty()
    "_id": ObjectId("59e8b136dfa9a3fbf0fd8238"),
    "Nome": "Paulo",
    "Telefone": "(85) 929292"
    "_id" : ObjectId("59e8b146dfa9a3fbf0fd8239"),
    "Nome": "Policia",
    "Telefone": "190"
```

```
> db.ListaTelefonica.update({Nome:"Paulo"},{Nome:"Paulo", Telefone:"(85)
923873727", tipo:"Celular"})
WriteResult({ "nMatched" : 1, "nUpserted" : 0, "nModified" : 1 })
> db.ListaTelefonica.find().pretty()
    "_id": ObjectId("59e8b3ccdfa9a3fbf0fd823a"),
    "Nome": "Paulo",
    "Telefone": "(85) 923873727",
    "tipo" : "Celular"
    " id": ObjectId("59e8b3d3dfa9a3fbf0fd823b"),
    "Nome": "Policia",
    "Telefone": "190"
```

```
> db.ListaTelefonica.update({Nome:"Paulo"},{$set:{ Telefone:"(85) 988888888"}})
WriteResult({ "nMatched" : 1, "nUpserted" : 0, "nModified" : 1 })
> db.ListaTelefonica.find().pretty()
    " id": ObjectId("59e8b3ccdfa9a3fbf0fd823a"),
    "Nome": "Paulo",
    "Telefone": "(85) 988888888",
    "tipo" : "Celular"
    " id" : ObjectId("59e8b3d3dfa9a3fbf0fd823b"),
    "Nome": "Policia",
    "Telefone": "190"
```

```
> db.ListaTelefonica.find({Nome:"Paulo"}).pretty()
    " id" : ObjectId("59e8b3ccdfa9a3fbf0fd823a"),
    "Nome": "Paulo",
    "Telefone": "(85) 988888888",
    "tipo" : "Celular"
> db.ListaTelefonica.remove({Nome:"Paulo"})
WriteResult({ "nRemoved" : 1 })
> db.ListaTelefonica.find().pretty()
    " id": ObjectId("59e8b3d3dfa9a3fbf0fd823b"),
    "Nome": "Policia",
    "Telefone": "190"
```

### MongoDB - Import DataSet

### >mongoimport -d bigdata -c things --type tsv --file c:\bigdata\dataset\201702\_gastosDiretos-utf.csv --headerline

```
2017-10-19T11:37:50.922-0300
                             connected to: localhost
2017-10-19T11:37:53.876-0300
                             [#.....] bigdata.things
                                                                          20.6MB/392MB (5.3%)
2017-10-19T11:37:56.876-0300
                             [##....] bigdata.things
                                                                          40.4MB/392MB (10.3%)
2017-10-19T11:37:59.876-0300
                             [###....] bigdata.things
                                                                          60.6MB/392MB (15.4%)
2017-10-19T11:38:02.876-0300
                             [####....] bigdata.things
                                                                          81.0MB/392MB (20.7%)
                             [#####....] bigdata.things
2017-10-19T11:38:05.876-0300
                                                                          94.1MB/392MB (24.0%)
2017-10-19T11:38:08.877-0300
                              [#######....] bigdata.things
                                                                          115MB/392MB (29.2%)
2017-10-19T11:38:11.877-0300
                              [########....] bigdata.things
                                                                          136MB/392MB (34.6%)
                             [#########..... bigdata.things
2017-10-19T11:38:14.879-0300
                                                                          157MB/392MB (40.0%)
2017-10-19T11:38:17.877-0300
                             [##########.....] bigdata.things
                                                                          178MB/392MB (45.4%)
2017-10-19T11:38:20.876-0300
                              [############..... bigdata.things
                                                                          198MB/392MB (50.4%)
2017-10-19T11:38:23.876-0300
                              [##############.....] bigdata.things
                                                                          218MB/392MB (55.6%)
                             [##############..... bigdata.things
2017-10-19T11:38:26.877-0300
                                                                          238MB/392MB (60.8%)
                             [###############.....] bigdata.things
2017-10-19T11:38:29.876-0300
                                                                          257MB/392MB (65.4%)
2017-10-19T11:38:32.876-0300
                             [################.....] bigdata.things
                                                                          273MB/392MB (69.5%)
2017-10-19T11:38:35.876-0300
                              [################# bigdata.things
                                                                          293MB/392MB (74.8%)
2017-10-19T11:38:38.878-0300
                              [#################.....] bigdata.things
                                                                          313MB/392MB (79.8%)
2017-10-19T11:38:41.882-0300
                             [################## bigdata.things
                                                                          334MB/392MB (85.1%)
2017-10-19T11:38:44.877-0300
                             [###################...] bigdata.things
                                                                          354MB/392MB (90.3%)
2017-10-19T11:38:47.876-0300
                              [###################..] bigdata.things
                                                                          375MB/392MB (95.5%)
2017-10-19T11:38:50.450-0300
                              [################# bigdata.things
                                                                          392MB/392MB (100.0%)
2017-10-19T11:38:50.451-0300
                             imported 927919 documents
```

```
> db.gastos.count()
927919
> db.gastos.findOne()
    "_id": ObjectId("59e8bcfdcdd0fefa043a2ea1"),
    "Código Órgão Superior": 20000,
    "Nome Órgão Superior": "PRESIDENCIA DA REPUBLICA",
    "Código Órgão": 20101,
    "Nome Órgao": "PRESIDENCIA DA REPUBLICA",
    "Código Unidade Gestora": 110001,
    "Nome Unidade Gestora": "SECRETARIA DE ADMINISTRACAO/PR",
    "Código Grupo Despesa": 3,
    "Nome Grupo Despesa": "Outras Despesas Correntes",
    "Nome Ação" : "Assistência Pré-Escolar aos Dependentes dos Servidores Civis, Empregados e Militares",
    "Linguagem Cidadã": "Assistência Pré-Escolar",
    "Código Favorecido": 191,
    "Nome Favorecido": "BANCO DO BRASIL SA [DIRECAO GERAL]",
    "Número Documento": "2017OB801077",
    "Gestão Pagamento": 1,
    "Data Pagamento": "24/02/2017",
    "Valor": "11156,55"
```

> db.gastos.aggregate([ {"\$group" : {\_id:"\$Nome Órgao", count:{\$sum:1}}} ]) { "id": "COMPANHIA BRASILEIRA DE TRENS URBANOS - CBTU", "count": 1640 } { " id": "FUNDO NACIONAL DE ASSISTENCIA SOCIAL", "count": 4 } { " id": "INSTITUTO NACIONAL DO SEGURO SOCIAL", "count": 15970 } { " id" : "INSTITUTO BRASILEIRO DE TURISMO", "count" : 433 } { " id": "SUPERINT. DE DESENV. DO CENTRO-OESTE - SUDECO", "count": 96 } { " id": "SUPERINTEND.DO DESENVOLV.DA AMAZONIA-SUDAM", "count": 129 } { " id": "EPU - REC. SOB SUPERVISAO DO MIN. AERONAUTICA", "count": 71 } { " id" : "FUNDO NAVAL", "count" : 5646 } { " id": "AMAZONIA AZUL TECNOLOGIAS DE DEFESA S.A.", "count": 182 } { " id": "CAIXA DE CONST.DE CASAS DO PESSOAL DA MARINHA", "count": 97 } { " id" : "FUNDACAO OSORIO", "count" : 50 } { "id": "DEPARTAMENTO NAC. DE OBRAS CONTRA AS SECAS", "count": 682 } { " id": "INDUSTRIA DE MATERIAL BELICO DO BRASIL-IMBEL", "count": 751 } { " id" : "COMANDO DA MARINHA", "count" : 6426 } { " id" : "COMANDO DA AERONAUTICA", "count" : 11437 } { " id" : "MINISTERIO DA DEFESA", "count" : 607 } { " id": "AUTORIDADE PUBLICA OLIMPICA - APO/FEDERAL", "count": 73 } { " id": "INST.CHICO MENDES DE CONSER.DA BIODIVERSIDADE", "count": 1826 } { " id": "AGENCIA NACIONAL DE AGUAS ± ANA", "count": 301 } { " id" : "AGENCIA NACIONAL DO CINEMA ± ANCINE", "count" : 330 }

```
> db.gastos.aggregate([ {"$group" : {_id:"$Nome Órgão Superior", valor:{$sum:"$Valor"}}} ])
{ "_id" : "MINISTERIO DAS CIDADES", "valor" : 127264010.74000001 }
{ "_id" : "MINISTERIO DO TURISMO", "valor" : 22155796.56 }
{ " id" : "MINISTERIO DA CULTURA", "valor" : 41833812.02 }
{ "_id" : "MINISTERIO DA INTEGRACAO NACIONAL", "valor" : 188860096.22 }
{ " id" : "MINISTERIO DO ESPORTE", "valor" : 27842774.69 }
{ "id": "MINIST.DOS TRANSP.,PORTOS E AVIACAO CIVIL", "valor": 686267918.95 }
{ " id": "MINISTERIO DAS RELACOES EXTERIORES", "valor": 10862974.24 }
{ "id": "MINISTERIO DA PREVIDENCIA SOCIAL", "valor": 199150935.17999998 }
{ "_id" : "MINISTERIO DA JUSTICA E SEGURANÇA PUBLICA", "valor" : 200284115.09 }
{ " id" : "MINISTERIO DA FAZENDA", "valor" : 1721389684.59 }
{ " id" : "MINISTERIO DE MINAS E ENERGIA", "valor" : 172570439.39000002 }
{ " id" : "MINISTERIO DA DEFESA", "valor" : 641760646.88 }
{ "_id" : "MINIST. DA AGRICUL.,PECUARIA E ABASTECIMENTO", "valor" : 120123058.51 }
{ "id": "MINIST. DA TRANSPARENCIA, FISCALIZACAO E CGU", "valor": 2576314.75 }
{ " id" : "MINISTERIO DA EDUCACAO", "valor" : 2165150592.07 }
{ " id" : "MINISTERIO DO TRABALHO", "valor" : 7025840035.13 }
{ "id": "MINIST. DO PLANEIAMENTO, DESENVOLV. E GESTAO", "valor": 49010021.77 }
{ "_id" : "MINIST.DA CIENCIA,TECNOL.,INOV.E COMUNICACOES", "valor" : 409432300.55 }
{ "id": "MINIST. DA INDUSTRIA, COM.EXTERIOR E SERVICOS", "valor": 13828517.06 }
{ "id": "MINISTERIO DO DESENVOLVIMENTO SOCIAL", "valor": 196723506.03 }
```

# MongoDB - Convertendo Valores para Float

```
db.gastos.find({"Valor": {$exists: true}}).forEach(function(doc){
   if(doc.Valor.length > 0){
      var newVal = doc.Valor.replace(',', '.');
      var valString = parseFloat(newVal).toFixed(2);
      doc.Valor = parseFloat(valString);
      db.gastos.save(doc);
      } // End of If Condition
   }) // End of foreach
```

